

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
по курсу
«Data Science»

Слушатель

Терещук Всеволод Олегович

Москва, 2022

Содержание

Содержание.....	2
Введение.....	3
1. Аналитическая часть.....	5
1.1. Постановка задачи	5
1.2. Разведочный анализ данных	7
2. Практическая часть.....	20
2.1. Предобработка данных.....	20
2.2. Разработка и тестирование моделей	24
2.3. Нейронная сеть, рекомендации соотношения матрица- наполнитель	30
Заключение	32
Список используемой литературы и ссылки на веб-ресурсы	32

Введение

Тема: Прогнозирование конечных свойств новых материалов (композиционных материалов).

Актуальность темы исследования: Изделия из полимерных композиционных материалов используются в разных секторах экономики, таких как машиностроение, строительство, радиоэлектроника и др. Работоспособность изделий зависит от многих факторов, включая от физико-механических параметров материалов, из которых они сделаны.

Каждый месяц производятся новые полимерные композиционные материалы. Главные эксплуатационные свойства этих материалов определяют, в основном, экспериментальными методами, что требует квалифицированных кадров, дорогостоящего оборудования и значительных временных и материальных затрат.

Одним из способов разработки новых композиционных материалов является структурное модифицирование, то есть изменение его физических свойств без изменения химического состава.

При данном виде улучшений полимера вводятся различные наполнители, которые приводят к изменению их эксплуатационных характеристик. В зависимости от характеристик наполнителей, химического состава, твердости и других показателей, а также их концентрации, можно получить самые разные свойства материала.

Оценка надежности конструкций по критерию прочности основана на сопоставлении характеристик напряженно-деформированного состояния и соответствующих предельных свойств материалов элементов конструкций.

Создание новых композиционных материалов и оценка их надежности требует нового подхода в определении деформационно-прочностных характеристик как основы оценки надежности конструкций, а также изучения возможности применения средств и методов вычислительной механики для моделирования

эффективных характеристик наполненных композиций и расчета вероятности безотказной работы изделий.

Как следствие, современным подходом к решению задач такого типа является применение технологий машинного обучения в целях исследования влияния одной или нескольких независимых переменных на зависимую переменную.

Актуальность решения задачи обусловлена широким использованием композитных материалов практически во всех областях производства.

Прогнозирование модели может существенно сократить количество проводимых испытаний, а также пополнить базу данных материалов новыми свойствами материалов, и цифровыми двойниками новых композитов.

1. Аналитическая часть

1.1 Постановка задачи.

Описание: Композиционные материалы — это искусственно созданные материалы, состоящие из нескольких других с четкой границей между ними. Композиты обладают теми свойствами, которые не наблюдаются у компонентов по отдельности. При этом композиты являются монолитным материалом, т. е. компоненты материала неотделимы друг от друга без разрушения конструкции в целом.

Актуальность: Созданные прогнозные модели помогут сократить количество проводимых испытаний, а также пополнить базу данных материалов возможными новыми характеристиками материалов, и цифровыми двойниками новых композитов.

На входе имеются два датасета о начальных свойствах компонентов композиционных материалов.

Первый датасет «X_br.xlsx» включает в себя десять переменных Базальтопластика, такие как соотношение матрица-наполнитель, плотность, модуль упругости, количество отвердителя, содержание эпоксидных групп, температура вспышки, поверхностная плотность, модуль упругости при растяжении, прочность при растяжении, потребление смолы. Выборка содержит 1023 замера.

Второй датасет «X_nup.xlsx» включает в себя три переменных накладок углепластиковых — угол нашивки, шаг нашивки, плотность нашивки. Выборка содержит 1040 замеров.

Данные таблицы имеют колонку с целочисленным индексом, не являющимся входным или выходным переменным, служащим для сопоставления таблиц данных.

На выходе необходимо спрогнозировать три параметра: модуля упругости при растяжении, прочности при растяжении, соотношение матрица-наполнитель.

Поставленная задача в рамках классификации категорий машинного обучения относится к машинному обучению с учителем, задача регрессии.

Анализ, предобработка данных, построение моделей выполнены посредством языка программирования Python с использованием библиотек Pandas, Matplotlib и Sklearn.

1.2 Разведочный анализ данных.

Целями разведочного анализа является получение первоначальных представлений о характерах распределений переменных исходного набора данных, формирование оценки качества исходных данных (наличие пропусков, выбросов), выявление характера взаимосвязи между переменными с целью последующего выдвижения гипотез о наиболее подходящих для решения задачи моделях машинного обучения.

Для начала производим объединение двух датасетов в один. Объединение производим по индексу, так как отсутствуют иные общие признаки. Тип объединения INNER, так как размеры датасетов не одинаковые, а разница в размере выборки всего 17 строк, проще данные показатели отбросить.

Следующим шагом проверяем объединённый датасет на наличие пропусков и определить тип данных.

```
df_merge.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 1023 entries, 0 to 1022
Data columns (total 13 columns):
 #   Column                                     Non-Null Count  Dtype
---  -
 0   Соотношение матрица-наполнитель         1023 non-null   float64
 1   Плотность, кг/м3                         1023 non-null   float64
 2   модуль упругости, ГПа                    1023 non-null   float64
 3   Количество отвердителя, м.%              1023 non-null   float64
 4   Содержание эпоксидных групп,%_2         1023 non-null   float64
 5   Температура вспышки, C_2                 1023 non-null   float64
 6   Поверхностная плотность, г/м2           1023 non-null   float64
 7   Модуль упругости при растяжении, ГПа    1023 non-null   float64
 8   Прочность при растяжении, МПа           1023 non-null   float64
 9   Потребление смолы, г/м2                 1023 non-null   float64
10  Угол нашивки, град                       1023 non-null   int64
11  Шаг нашивки                             1023 non-null   float64
12  Плотность нашивки                       1023 non-null   float64
dtypes: float64(12), int64(1)
memory usage: 111.9 KB
```

Рисунок 1 – Информация о пропусках и типе данных

Сформированный исходный датафрейм содержит 1023 записи с 10 входными параметрами и 3 выходными параметрами. В объединённом датасете отсутствуют пропуски, тип данных только числовой в соответствии с рисунком 1.

Следующим шагом проверяем на наличие дубликатов данных. В соответствии с рисунком 2, дубликаты данных в объединённом датасете отсутствуют.

```
df_merge.duplicated().sum()
```

0

Рисунок 2 – Наличие дубликатов записей

Следующим шагом проводить визуализацию данных. Построение гистограмм и диаграмм размаха («ящик с усами») позволяют получить наглядное представление о характерах распределений переменных.

Первым шагом отрисуем гистограммы распределения каждой переменной.

```
for col in df_merge.columns:  
    plt.figure(figsize=(15, 5))  
    sns.histplot(data=df_merge[col])  
    plt.show()
```




Рисунок 3 – Гистограмма соотношения матрицы-наполнителя




Рисунок 4 – Гистограмма плотности, кг/м³




Рисунок 5 – Гистограмма модуля упругости, ГПа




Рисунок 6 – Гистограмма количества отвердителя, м.%




Рисунок 7 – Гистограмма содержания эпоксидных групп, %₂




Рисунок 8 – Гистограмма температуры вспышки, C₂




Рисунок 9 – Гистограмма поверхностной плотности, г/м²




Рисунок 10 – Гистограмма модуля упругости при растяжении, ГПа




Рисунок 11 – Гистограмма прочности при растяжении, МПа




Рисунок 12 – Гистограмма потребления смолы, г/м²




Рисунок 13 – Гистограмма угла нашивки, град




Рисунок 14 – Гистограмма шага нашивки




Рисунок 15 – Гистограмма плотности нашивки

В соответствии с рисунками 3-12,14,15 распределение нормальное, имеются выбросы. Ярко выраженные выбросы содержатся в гистограммах

плотность в соответствии с рисунком 4, количества отвердителя в соответствии с рисунком 6, содержание эпоксидных групп в соответствии с рисунком 7, температура вспышки в соответствии с рисунком 8, плотность нашивки растяжении в соответствии с рисунком 15. Гистограмма угла нашивки имеет бинарное значение в соответствии с рисунком 13.

Вторым шагом построим диаграммы «ящик с усами» для каждого признака. Это поможет нам определить все выбросы и избавиться от них в дальнейшем для того, чтобы набор данных имел более сглаженный вид с точки зрения нормализации.




Рисунок 16 – График соотношения матрицы-наполнителя




Рисунок 17 – График плотности,
кг/м³




Рисунок 18 – График модуля упруго-
сти, ГПа




Рисунок 19 – График количества
отвердителя, м.%




Рисунок 20 – График содержания
эпоксидных групп, %_2




Рисунок 21 – График температуры вспышки, C_2




Рисунок 22 – График поверхностной плотности, $г/м^2$




Рисунок 23 – График модуля упругости при растяжении, $ГПа$




Рисунок 24 – График прочности при растяжении, $МПа$




Рисунок 25 – График потребления смолы, г/м²




Рисунок 26 – График угла нашивки, град




Рисунок 27 – График шага нашивки




Рисунок 28 – График плотность нашивки

Диаграммы «Ящик с усами» показали, что у всех признаков в соответствии с рисунками 16-25, 27,28 имеются выбросы. Выбросы не имеют

экстремально больших отклонений. График «Угол нашивки» не имеет выбросов, так как имеет 2 значения (0 градусов и 90 градусов), в соответствии с рисунком 26.

Следующим шагом разведочного анализа построим попарные графики рассеяния точек в соответствии с рисунком 29 и тепловую карту матрицы корреляции в соответствии с рисунком 30, для визуализации наличия зависимости признаков.

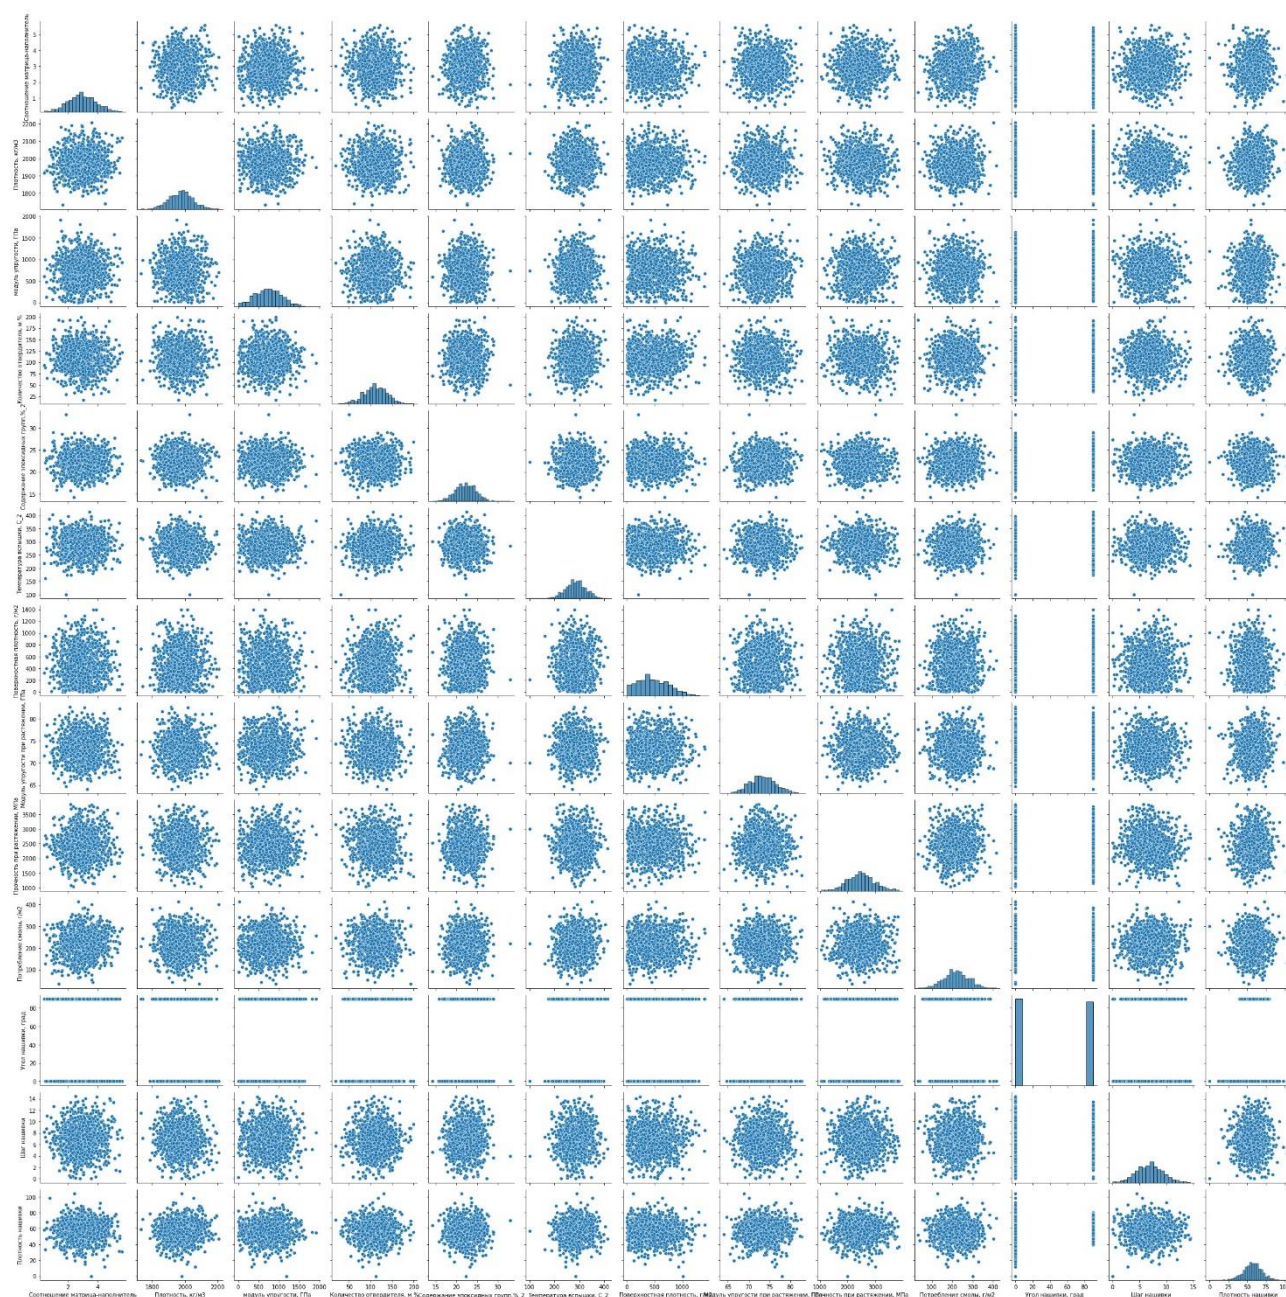


Рисунок 29 – График попарного рассеяния точек

```
corrmat = df_merge.corr()

f, ax = plt.subplots(figsize =(15, 12))
sns.heatmap(corrmat, ax = ax, cmap ="YlGnBu", linewidths = 0.1, annot = True)
```




Рисунок 30 – Тепловая карта матрицы корреляции

Как видно по рисунку 30, попарное сравнение признаков, зависимости не выявило. Также корреляционная матрица, тоже не выявила каких-либо зависимостей. Зависимость между признаками очень низкая. Самая высокая зависимость между углом нашивки и плотность нашивки (0,11).

Финальным шагом разведочного анализа посчитаем среднее в соответствии с рисунком 31 и медианное значение в соответствии с рисунком 32, для каждого признака.

df_merge.mean()	
Соотношение матрица-наполнитель	2.930366
Плотность, кг/м3	1975.734888
модуль упругости, ГПа	739.923233
Количество отвердителя, м.%	110.570769
Содержание эпоксидных групп,%_2	22.244390
Температура вспышки, С_2	285.882151
Поверхностная плотность, г/м2	482.731833
Модуль упругости при растяжении, ГПа	73.328571
Прочность при растяжении, МПа	2466.922843
Потребление смолы, г/м2	218.423144
Угол нашивки, град	44.252199
Шаг нашивки	6.899222
Плотность нашивки	57.153929
dtype: float64	

Рисунок 31 – Среднее значение признаков

df_merge.median()	
Соотношение матрица-наполнитель	2.906878
Плотность, кг/м3	1977.621657
модуль упругости, ГПа	739.664328
Количество отвердителя, м.%	110.564840
Содержание эпоксидных групп,%_2	22.230744
Температура вспышки, С_2	285.896812
Поверхностная плотность, г/м2	451.864365
Модуль упругости при растяжении, ГПа	73.268805
Прочность при растяжении, МПа	2459.524526
Потребление смолы, г/м2	219.198882
Угол нашивки, град	0.000000
Шаг нашивки	6.916144
Плотность нашивки	57.341920
dtype: float64	

Рисунок 32 – Медианное значение признаков

В результат проведенного разведочного анализа мы можем сделать следующие выводы. У почти у всех признаков имеется нормальное распределение и по имеющейся информации, данные являются предварительно обработанными заказчиком. Пропуски в заполнении данных отсутствуют. Взаимозависимость признаков почти полностью отсутствует. Очень слабая зависимость есть между углом нашивки и плотность нашивки. Исходные датасеты имеют разный размер, но так как разница в размере выборки составляет всего 17 замеров или 1,66 процента от размера выборки «X_br.xlsx», я отбросил лишние данные и произвел объединение по типу inner.

2. Практическая часть

2.1 Предобработка данных

Для начала, посчитаем количество выбросов. В соответствии с моим предположением выбросов должно быть не много, исходя из диаграмм «ящик усами». Для этого посчитаем количество выбросов двумя основными способами. Методом 3-х сигм и методом межквартильных расстояний.

```
count_3s = 0
count_iq = 0
for column in df_merge:
    d = df_merge.loc[:, [column]]
    # методом 3-х сигм
    zscore = (df_merge[column] - df_merge[column].mean()) / df_merge[column].std
    d['3s'] = zscore.abs() > 3
    count_3s += d['3s'].sum()
    # методом межквартильных расстояний
    q1 = np.quantile(df_merge[column], 0.25)
    q3 = np.quantile(df_merge[column], 0.75)
    iqr = q3 - q1
    lower = q1 - 1.5 * iqr
    upper = q3 + 1.5 * iqr
    d['iq'] = (df_merge[column] <= lower) | (df_merge[column] >= upper)
    count_iq += d['iq'].sum()
print('Метод 3-х сигм, выбросов:', count_3s)
print('Метод межквартильных расстояний, выбросов:', count_iq)
```

Метод 3-х сигм, выбросов: 24

Метод межквартильных расстояний, выбросов: 93

Рисунок 33 – Количество выбросов

В соответствии с рисунком 33, метод 3-х сигм нашел меньше выбросов 24 выброса, против 93 у метода межквартильных расстояний. Учитывая тот факт, что данные были предварительно подготовлены заказчиком и то, что график "ящик с усами" показывает небольшое количество выбросов и не самый большой размах. С целью того, чтобы избежать удаления тех данных, которые могут оказаться не выбросами, а особенностями датасета, я оставил свой выбор за методом 3-х сигм.

Для того чтобы не допустить ошибки и не удалить особенности признака. Посчитаем распределение выбросов по признакам в соответствии с рисунком 34.

```
t_df = df_merge.copy()
for i in df_merge.columns:
    t_df[i] = abs((df_merge[i] - df_merge[i].mean()) / df_merge[i].std())
    print(f"{sum(t_df[i] > 3)} выбросов в признаке {i}")
print(f'Всего {sum(sum(t_df.values > 3))} выброса')
```

```
0 выбросов в признаке Соотношение матрица-наполнитель
3 выбросов в признаке Плотность, кг/м3
2 выбросов в признаке модуль упругости, ГПа
2 выбросов в признаке Количество отвердителя, м.%
2 выбросов в признаке Содержание эпоксидных групп,%_2
3 выбросов в признаке Температура вспышки, С_2
2 выбросов в признаке Поверхностная плотность, г/м2
0 выбросов в признаке Модуль упругости при растяжении, ГПа
0 выбросов в признаке Прочность при растяжении, МПа
3 выбросов в признаке Потребление смолы, г/м2
0 выбросов в признаке Угол нашивки, град
0 выбросов в признаке Шаг нашивки
7 выбросов в признаке Плотность нашивки
Всего 24 выброса
```

Рисунок 34 – Распределение выбросов по признакам

Как видно из расчёта в соответствии с рисунком 34, выбросы распределены по разным признакам. Нет какой-либо чрезмерной концентрации в одном признаке. Соответственно можно приступать к удалению признака, так как существенных изменений на зависимости они не окажут.

Следующим шагом произведем удаление выбросов из датасета и проверку изменения количества строк.

```
clean_outliers_df_merge = df_merge[(np.abs(stats.zscore(df_merge)) <= 3).all(axis=1)]
clean_outliers_df_merge
```

	Соотношение матрица-наполнитель	Плотность, кг/м3	модуль упругости, ГПа	Количество отвердителя, м.%	Содержание эпоксидных групп,%_2	Температура вспышки, С_2	Поверхностная плотность, г/м2	Модуль упругости при растяжении, ГПа	Прочность при растяжении, МПа	Потребление смолы, г/м2	Угол нашивки, град
1	1.857143	2030.000000	738.736842	50.000000	23.750000	284.615385	210.000000	70.000000	3000.000000	220.000000	0
3	1.857143	2030.000000	738.736842	129.000000	21.250000	300.000000	210.000000	70.000000	3000.000000	220.000000	0
4	2.771331	2030.000000	753.000000	111.860000	22.267857	284.615385	210.000000	70.000000	3000.000000	220.000000	0
5	2.767918	2000.000000	748.000000	111.860000	22.267857	284.615385	210.000000	70.000000	3000.000000	220.000000	0
6	2.569620	1910.000000	807.000000	111.860000	22.267857	284.615385	210.000000	70.000000	3000.000000	220.000000	0
...
1018	2.271346	1952.087902	912.855545	86.992183	20.123249	324.774576	209.198700	73.090961	2387.292495	125.007669	90
1019	3.444022	2050.089171	444.732634	145.981978	19.599769	254.215401	350.660830	72.920827	2360.392784	117.730099	90
1020	3.280604	1972.372865	416.836524	110.533477	23.957502	248.423047	740.142791	74.734344	2662.906040	236.606764	90
1021	3.705351	2066.799773	741.475517	141.397963	19.246945	275.779840	641.468152	74.042708	2071.715856	197.126067	90
1022	3.808020	1890.413468	417.316232	129.183416	27.474763	300.952708	758.747882	74.309704	2856.328932	194.754342	90

999 rows × 13 columns

Рисунок 35 – Удаление выбросов

В соответствии с рисунком 35, видно, что количество строк в датасете уменьшилась на 24 замера, что составляет 2,35 процентов от исходной выборки.

Проверим корреляцию признаков. Чтобы посмотреть, как изменились зависимости, после удаления выбросов.




Рисунок 36 - Тепловая карта матрицы корреляции с удаленными выбросами

В соответствии с рисунком 36, видно, что в результате удаления выбросов, корреляция изменилась не значительно. Где-то возросла, где-то уменьшилась. Но существенных изменений нет, корреляция между признаками по-прежнему, фактически отсутствует.

Очистив, дата сет от выбросов, построим график распределения плотности ядра, для оценки необходимости нормализации.

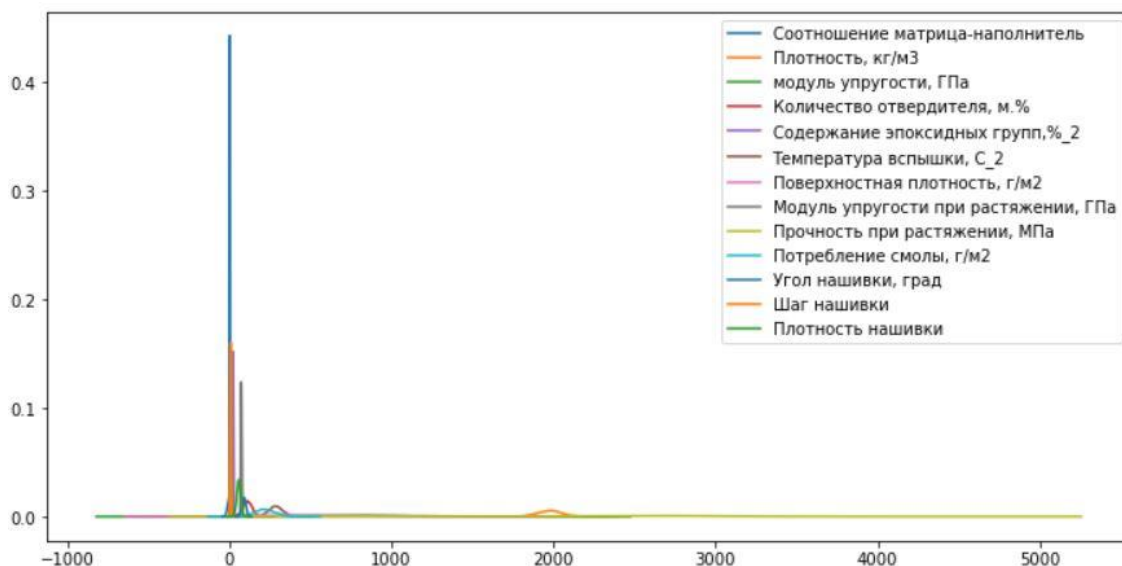


Рисунок 37 – График распределения плотности ядра

В соответствии с рисунком 37 наглядно видно, что данные находятся в очень разных диапазонах. Так как диапазоны очень разные, необходимо провести нормализацию данных.

Проведём нормализацию данных в соответствии с рисунком 38.

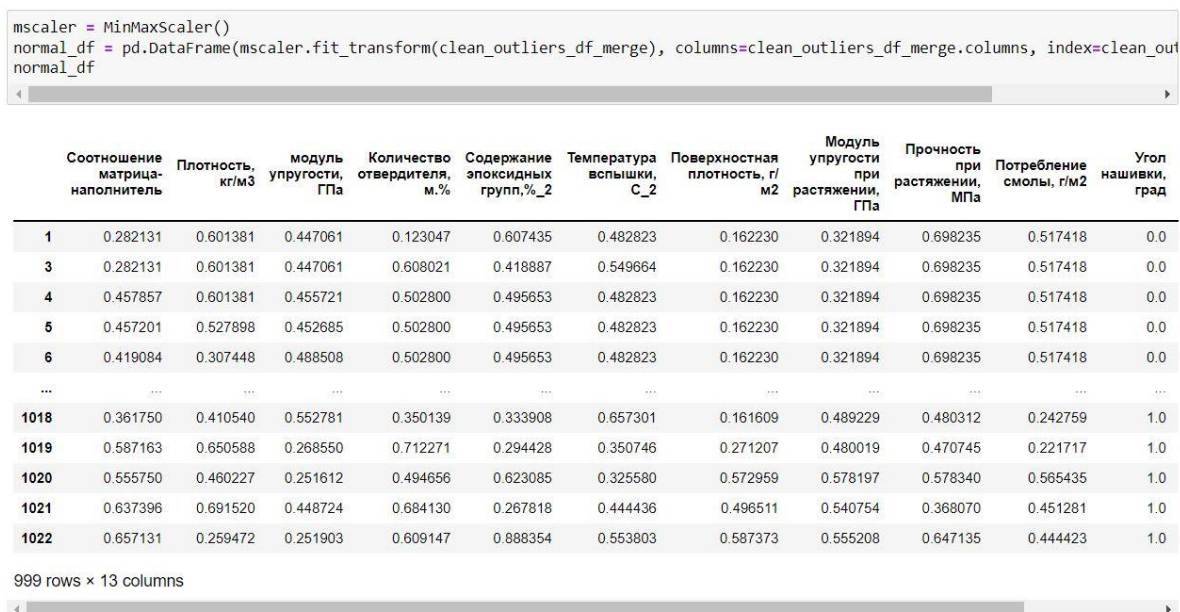


Рисунок 38 – График нормализации данных

Предобработку данных закончили. Удалили выбросы и нормализовали значения данных.

2.2 Разработка и тестирование моделей

В соответствии с поставленной задачей, нужно осуществить разработку и обучение моделей машинного обучения для двух выходных параметров: «Прочность при растяжении» и «Модуль упругости при растяжении». Для каждого признака построение моделей осуществляется отдельно. Разделение нормализованных данных на обучающую и тестовую выборки (в соотношении 70 на 30%, согласно поставленной задаче).

Для признака «Прочность при растяжении» были разработаны и обучены следующие модели в соответствии с рисунком 39:

- модель на основе линейной регрессии (метод `LinearRegression`);
- модель случайный лес (метод `RandomForestRegressor()`);
- модель k ближайших соседей (метод `KNeighborsRegressor()`);
- модель Стохастический градиентный спуск (метод `SGDRegressor ()`);

	R2	RMSE	MAE
<code>LinearRegression</code>	-0.033892	-0.169358	-0.136618
<code>SGDRegressor</code>	-0.062455	-0.171611	-0.137729
<code>KNeighborsRegressor</code>	-0.184717	-0.180367	-0.145637
<code>RandomForestRegressor</code>	-0.102962	-0.174804	-0.139260

Рисунок 39 – График оценки моделей

Как видно из таблицы оценки, все модели не смогли выявить зависимости и предсказать прогноз модуля упругости при растяжении. Лучшие результаты у линейной регрессии. По заданию у нас задача построить модели и найти лучшие гиперпараметры. Построим для некоторых моделей графики и поиск гиперпараметров.

Линейная регрессия:




Рисунок 40 – Линейная модель модуля упругости при растяжении

Модель линейной регрессе не справилась с задачей в соответствии с рисунком 40. Не смогла выявить зависимость. Гиперпараметров у линейной регрессии нет, соответственно подбор оптимальных гиперпараметров не является возможным. Средняя оценка эффективности модели минус 3,4 процента.

Случайный лес:




Рисунок 41 – Модель случайный лес

Случайны лес, в соответствии с рисунком 41, тоже не справился с задачей и не смог выявить зависимость. Подбор оптимальных гиперпараметров не повысил эффективность модели ('bootstrap': True, 'max_depth': 1, 'min_samples_leaf': 4, 'min_samples_split': 24, 'n_estimators': 15). Ее точность осталась в районе минус 11,1 процентов. Что хуже линейной регрессии.

К-ближайших соседей:




Рисунок 42 – Модель к-ближайших соседей

К -ближайших соседей тоже не справился с задачей и не смог выявить зависимость. Подбор оптимальных гиперпараметров не существенно повысил эффективность модели ('n_neighbors': 38). Ее точность осталась в районе минус 18,5 процентов. Что хуже линейной регрессии.

Стохастический градиентный спуск:




Рисунок 43 – Модель стохастический градиентный спуск

Стохастический градиентный спуск тоже не справился с задачей и не смог выявить зависимость. Подбор оптимальных гиперпараметров не существенно

повысил эффективность модели ('loss': 'squared_epsilon_insensitive', 'penalty': 'l2'). Ее точность осталась в районе минус 6,1 процентов. Что хуже линейной регрессии.

Модуль упругости не имеет линейной зависимости. Линейная регрессия, случайный лес, стохастический градиентный спуск и метод К ближайших соседей не справились с задачей. Свойства композитных материалов в первую очередь зависят от используемых материалов.

Перейдем ко второму признаку «Прочность при растяжении».

Для признака «Прочность при растяжении» были разработаны и обучены следующие модели в соответствии с рисунком 44:

- модель на основе линейной регрессии (метод `LinearRegression`);
- модель дерева решений (метод `DecisionTreeRegressor()`);
- модель градиентный бустинг (метод `GradientBoostingRegressor ()`);

	R2	RMSE	MAE
LinearRegression	-0.026373	-0.174856	-0.139328
DecisionTreeRegressor	-1.177100	-0.254491	-0.202492
GradientBoostingRegressor	-0.105680	-0.181391	-0.144344

Рисунок 44 – График оценки моделей

Как видно из таблицы оценки, все модели не смогли выявить зависимости и предсказать прогноз прочности при растяжении. Лучшие результаты у линейной регрессии. По заданию у нас задача у нас построить моделей и найти лучшие гиперпараметры. Построим для некоторых моделей графики и поиск гиперпараметров.

Линейная регрессия:




Рисунок 45 – Линейная модель прочности при растяжении

Модель линейной регрессе не справилась с задачей в соответствии с рисунком 45. Не смогла выявить зависимость. Гиперпараметров у линейной регрессии нет, соответственно подбор оптимальных гиперпараметров не является возможным. Средняя оценка эффективности модели минус 2,6 процента.

Деревья решений:




Рисунок 46 – Модель дерева решений

Деревья решений тоже не справился с задачей и не смог выявить зависимость. Подбор оптимальных гиперпараметров не существенно повысил

эффективность модели ('criterion': 'poisson', 'max_depth': 11, 'max_features': 'auto', 'min_samples_leaf': 100, 'min_samples_split': 300, 'splitter': 'random'). Ее точность осталась в районе минус 117 процентов. Что хуже линейной регрессии.

Градиентный бустинг:




Рисунок 46 – Модель градиентный бустинг

Градиентный бустинг тоже не справился с задачей и не смог выявить зависимость. Подбор оптимальных гиперпараметров не существенно повысил эффективность модели ('criterion': 'mae', 'loss': 'absolute_error', 'max_depth': 2, 'min_samples_split': 7, 'n_estimators': 10). Ее точность осталась в районе минус 10,8 процентов. Что хуже линейной регрессии.

Прочность при растяжении не имеет линейной зависимости. Линейная регрессия, деревья решений, градиентный бустинг не справились с задачей. Прочность при растяжении зависит от методики проверки материала. Одному значению прочность при растяжении, могут соответствовать множество материалов в различных экспериментах.

2.3 Нейронная сеть, рекомендации соотношения матрица-наполнитель

Для рекомендации соотношения «матрица-наполнитель» была разработана простая модель глубокого обучения с помощью библиотеки Keras.

Архитектура нейронной сети может быть описана следующим образом.

Модель состоит из четырех скрытых уровней. Первый содержит 64 нейрона. Последующие скрытые уровни – они содержат 64, 64 и 1 нейрона. Снижение числа нейронов на каждом уровне сжимает информацию, которую сеть обработала на предыдущих уровнях.

Для эксперимента был выбран `relu` (выпрямленная линейная единица).

После обучения модели для была определена средняя абсолютная ошибка и среднеквадратическая ошибка на тестовом наборе данных в соответствии с рисунком 47. Результат оказался тоже неудовлетворительный как и в предыдущих экспериментах.

```
mse: 0.04877017065882683  
mae 0.17474602162837982
```

Рисунок 47 – Оценка нейронной сети

3. Заключение

Теоретически разработанный метод определения надёжности изделий из композиционных материалов, основанный на использовании статистически достоверных характеристик материалов, полученных физическим и вычислительным экспериментом, позволяет оценивать уровень надёжности изделий как в отдельных точках, так и по всему объёму в целом.

Результаты работы выложены на GitHub:

https://github.com/vsevolod008/bmstu_qualifying_work

4. Список используемой литературы и ссылки на веб-ресурсы

[1] В.В. Васильев, В.Д. Протасов, В.В. Болотин и др.: Композитные материалы: справочник. Москва: Машиностроение, 1990, 510 с.

[2] Плас Дж. Вандер, Python для сложных задач: наука о данных и машинное обучение. Санкт-Петербург: Питер, 2018, 576 с.

[3] Язык программирования Python: - Режим доступа: <https://www.python.org/> (дата обращения 01.04.2022)

[4] Библиотека Pandas – Режим доступа: <https://pandas.pydata.org/> (дата обращения 01.04.2022)

[5] Библиотека Matplotlib – Режим доступа: <https://matplotlib.org/> (дата обращения 01.04.2022)

[6] Библиотека Sklearn – Режим доступа: <https://scikit-learn.org/stable/> (дата обращения 01.04.2022)

[7] К. Андерсон, Аналитическая культура. От сбора данных до бизнес-результатов: монография. Москва: O'Reilly, 2017, 392 с.

[8] How to choose a machine learning model in Python? – Режим доступа: <https://www.codeastar.com/choose-machine-learning-models-python/> (дата обращения 03.04.2022)